



UFRJ
UNIVERSIDADE FEDERAL
DO RIO DE JANEIRO




Engenharia
Elétrica
UFRJ



Aprendizado por reforço utilizando Algoritmos Genéticos

CPE 723 – Otimização Natural
Antonioni Barros Campos

Problema



Gym: Interface para aprendizado por reforço e uma **coleção diversa de ambientes de referência.**



Lunar Lander

Análise

Estratégia de Evolução (ES)

- Representação Contínua
- Seleção dos pais – aleatória e uniforme
- Recombinação – Discreta e Intermediária
- Mutação – Gaussiana não correlacionada com n tamanhos de passos
- Seleção dos sobreviventes – Determinística (Elitismo) a partir dos filhos




Programação Evolucionária (EP)

- Representação Contínua
- Seleção dos pais – Determinístico (todos os pais sofrem mutação gerando um filho)
- Mutação – Gaussiana (EP) e Cauchy (FEP) não correlacionada com n tamanhos de passos
- Seleção dos sobreviventes – Determinística (Elitismo) a partir dos pais e filhos

Análise

Algoritmo	População	MBF	AES*
ES	100	96.20	450.800
ES	150	101.59	576.450
EP	100	72.35	-
EP	150	72.95	85.650
FEP	100	59.63	38.600
FEP	150	66.40	31.500

1000 Gerações, 128 unidades na camada oculta



Conclusões

- A etapa de recombinação implementada na Estratégia de Evolução demonstrou ter importância no problema gerando indivíduos mais aptos.
- Por outro lado, a Programação Evolucionária (EP/FEP) demonstrou alcançar indivíduos com aptidão relativamente alta com uma menor quantidade de chamadas à função de aptidão.
- Uma Rede Neural com uma única camada mostrou-se não ser suficiente para obter resultados no patamar de solução do problema.